杭州电子科技大学

《机器学习课程实践》

实验报告

题　　目　基于机器学习的径流预测

专　　业　待填写

学　　号　待填写（三名成员）

姓　　名　待填写（三名成员）

指导教师　待填写

成　　绩　待填写

二〇二六 年 十一 月 十一 日

一、任务要求

本课题根据流域逐日径流和气象观测，预测未来 1—7 天的径流，属于监督学习中的时间序列多步回归任务。输入为预测原点 t 当天已观测值及其历史，输出为 t+1 至 t+7 的流量。

实验依次完成数据分析、因果特征工程、人工神经网络/随机森林/LSTM 建模、简单平均与 Stacking 集成。三种基模型各构建七个直接模型与一个七输出模型，共 24 个；两类集成共 16 个。全程只使用教师 CSV。

正式回溯测试的最高 h=1 R^2 为 0.5103（multi/RF），RMSE 为 589.20，MAE 为 194.99。本次未达到约 0.8 目标。所有结果以原始流量尺度报告，不将相关系数平方替代 R^2。

二、详细分工

成员姓名	学号	具体分工
待填写	待填写	待填写真实承担任务
待填写	待填写	待填写真实承担任务
待填写	待填写	待填写真实承担任务

三、过程设计

步骤	工具或方法	处理目标
数据读取	pandas 与日期断言	核验 1827 行、9 列、连续日期和缺失
数据分析	直方图/箱型图/Pearson	解释分布、极端值和滞后相关
特征工程	日历编码/滞后/滚动/MI/Z-score	构建预测时点可得输入；折内拟合
个体建模	ANN/RF/LSTM 及 GridSearchCV	训练期选参，原生多输出
融合	简单平均/嵌套 OOF/Ridge	生成真实集成预测
冻结评价	359 个原点/三指标	一次评价 2004，归档报告与代码

训练数据为 2000—2003 年。为保证七步标签全部留在训练期，训练预测原点最晚到 2003-12-24。正式测试预测原点为 2004-01-01 至 2004-12-24，共 359 行。每行标签为未来 1—7 天，同一原点同时用于所有策略。2004 年内较早日期的已观测径流可作为随后原点的输入，这是滚动预报，不是用测试标签拟合模型。

开发采用两折 TimeSeriesSplit，gap=7。Stacking 采用三折外层 OOF，每个外层训练段再独立两折网格搜索[5]。训练标签最晚日期必须早于验证起点。每次 fit 重新计算互信息、缩放和模型参数；验证与测试不参与这些统计。

方法依据与适用范围

随机森林通过多棵树的集成降低单棵树的方差[2]，适合作为本实验的非线性回归基线；人工神经网络通过反向传播学习非线性关系[7]，但在四年日样本上需要控制网络容量和训练

预算。LSTM 以门控状态处理历史序列[3]，本实验只让它读取起报日及此前的观测，不把未来气象当成已知输入。Stacking 以基模型的折外预测构造第二层输入[4]，因此元学习器的拟合样本不能与基模型的拟合样本混同。三种个体方法和两种集成均采用同一测试日期与原始流量尺度，比较才有意义。

直接策略分别拟合 h=1 至 7 七个单输出模型，允许不同预见期选择不同参数；多输出策略一次拟合七列目标，利用目标间共享结构。两者各有七个最终预见期结果，但模型计数不同：每类个体模型为七个直接模型加一个多输出模型。简单平均与 Stacking 也遵循相同的八模型计数。递归策略需要把前一步预测再次送入下一步，误差会逐步传播，且并非本次指导书要求，故不列入正式比较。

整条实验流程采用同一预测原点定义。先用教师 CSV 建立按日排序的原始表，再从每个起报日向前取历史窗口，形成输入 X 及七列未来标签 y。开发阶段只在训练年份内部划分时间折，网格搜索给出每个模型的超参数；选择完成后，正式模型在允许的全部训练行上重新拟合。最后保存每个起报日、目标日期、真实值和预测值，再由逐日文件计算指标。这样既能逐条追查某个洪峰日为什么产生大误差，也能避免只保留一张汇总表而无法核对指标分母。所有模型共享同一组 359 个测试起报日，比较模型时不因缺失日期改变样本组成。

四、编码实现及结果

开发环境与数据核验

操作系统 Windows；Python 3.13.5；numpy 2.1.3，pandas 2.2.3，scikit-learn 1.6.1，torch 2.7.1+cu118，matplotlib 3.10.0，python-docx 1.2.0。保存的 LSTM 模型记录训练设备为 cuda；报告生成时 GPU 核验为 NVIDIA GeForce RTX 4060 Laptop GPU。所有随机种子固定为 42。

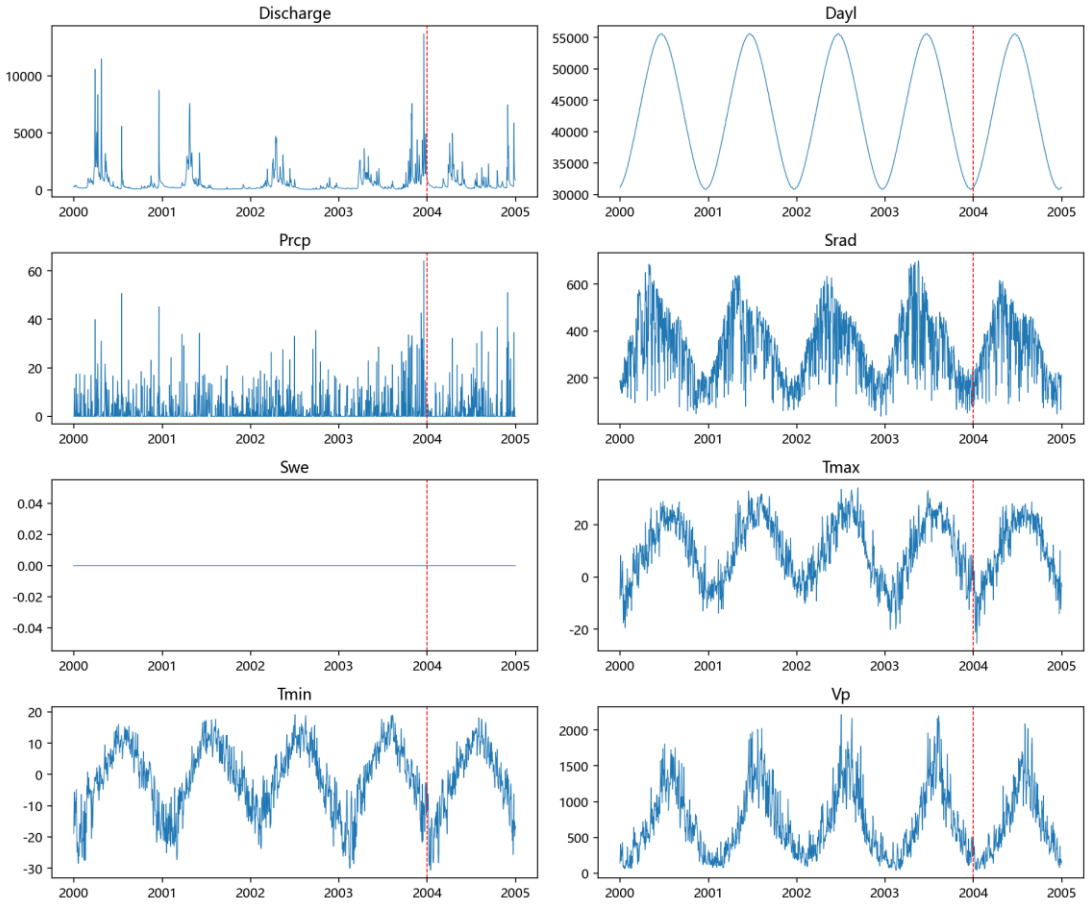
CSV 包含 2000-01-01 至 2004-12-31 的 1827 条日记录，字段无缺失。Swe 恒零，仅在建模时排除，原始观测保持不变。Discharge 的物理单位未在教师资料中明确，本报告保留原值并将 RMSE/MAE 标为原始流量单位，不擅自换算。

Daymet 官方资料给出了逐日降水、气温、短波辐射、水汽压、雪水当量和日长等字段定义[1]；这里使用的是教师已经整理的单站 CSV，不从官网追加年份或空间网格。检查日期连续性、字段缺失与常量列后再建模，是为了让每一个滞后量都对应确定的历史日期。对箱型图中的大流量值只标注为极端观测，不凭视觉判断为录入错误；删除洪峰会改变本题最关心的预报难度，也会使模型间比较失去原有数据口径。

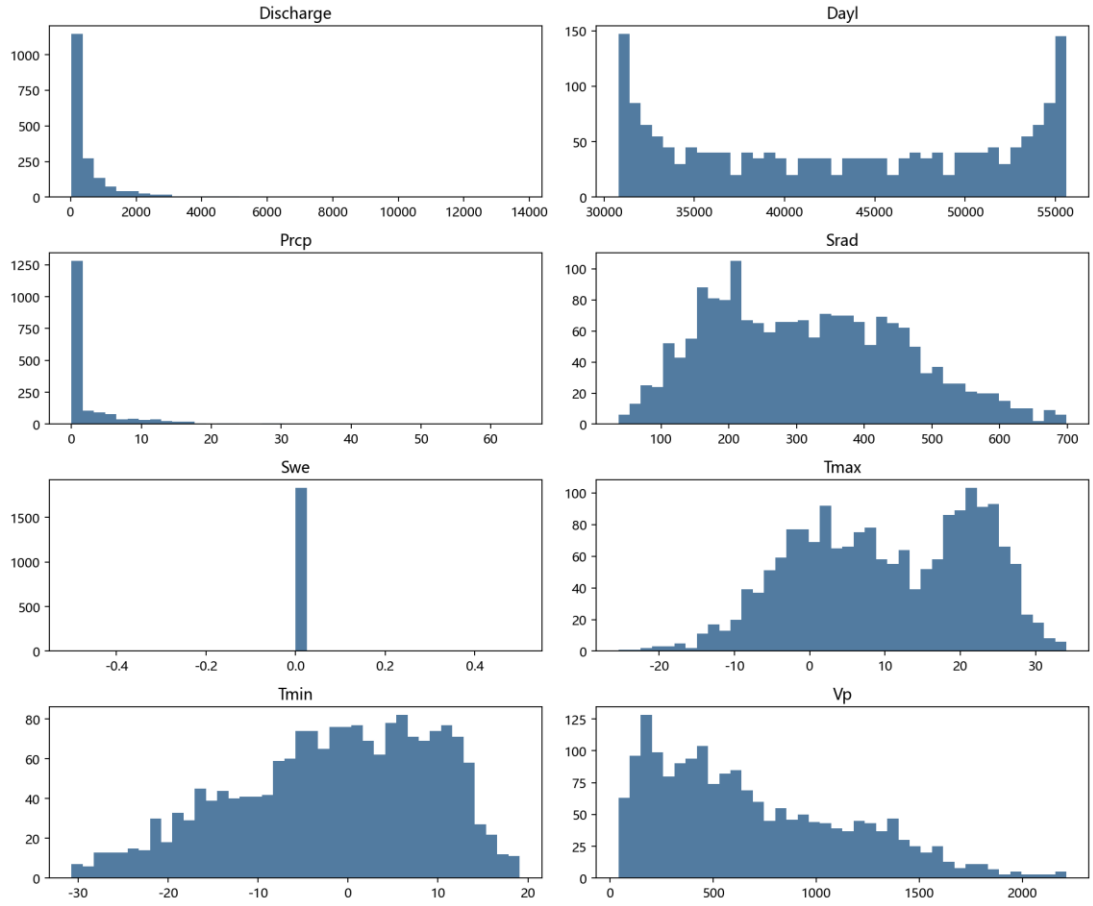
field	中文含义	单位
Date	日期	年-月-日
Discharge	径流流量	原始流量单位（教师资料未明确，未换算）

field	中文含义	单位
Dayl	日长	s/day
Prcp	降水量	mm/day
Srad	短波辐射	W/m²
Swe	雪水当量	kg/m²
Tmax	日最高气温	℃
Tmin	日最低气温	℃
Vp	水汽压	Pa

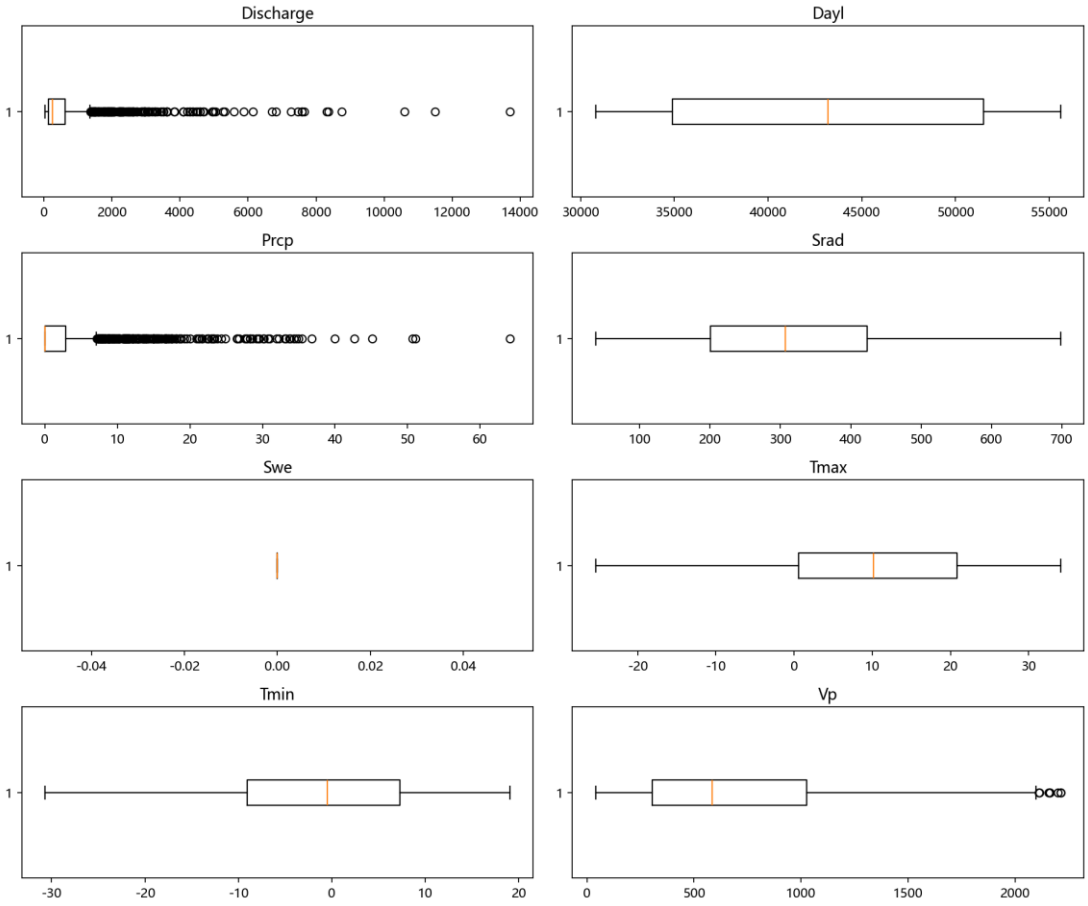
字段	mean	std	min	max
Discharge	610.8927	1058.8363	29.0000	13700.0000
Dayl	43186.7396	8526.6102	30791.5300	55608.4500
Prcp	2.8573	6.2431	0.0000	64.1200
Srad	316.1614	141.3489	37.0000	698.3500
Swe	0.0000	0.0000	0.0000	0.0000
Tmax	10.2232	11.7445	-25.3800	34.0700
Tmin	-1.6356	10.9938	-30.7100	19.0600
Vp	693.9145	472.8163	40.0000	2212.9100



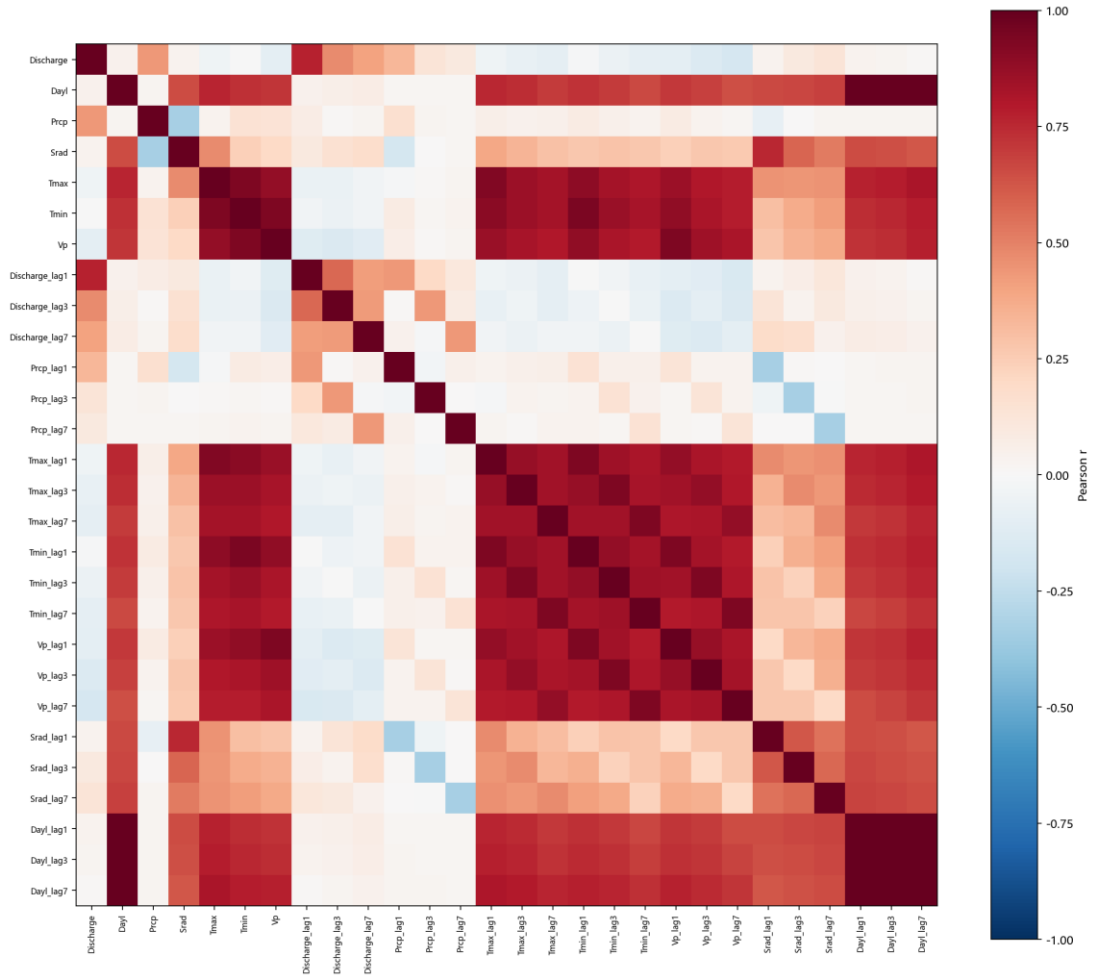
全部八个非日期字段时间序列，红线为 2004 年分界



全部八个非日期字段直方图



全部八个非日期字段箱型图



径流、因子及 1/3/7 天滞后 Pearson 相关性

特征构造与训练折内处理

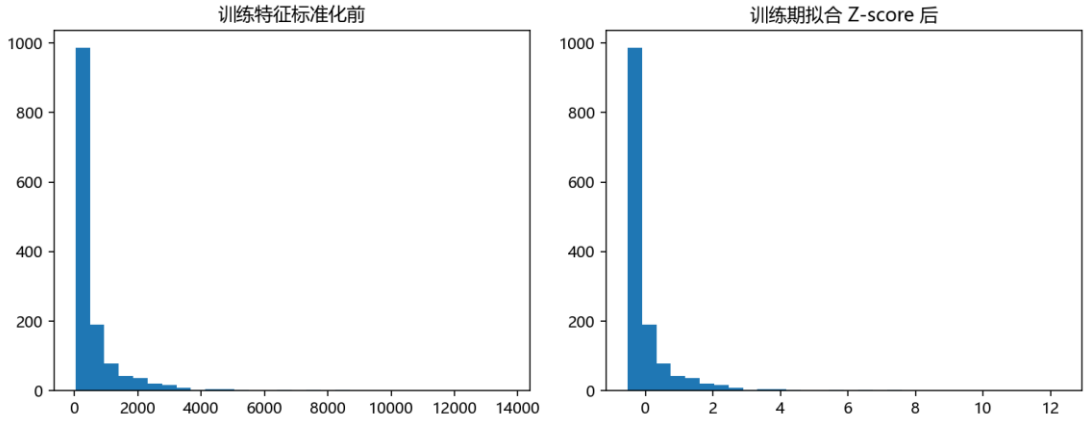
构建月份正余弦与四季 one-hot，冬季为 12—2 月。非恒定字段构建滞后 0/1/2/3/7/14/30 天；径流、降水、最高/最低气温构建 3/7/14 天滚动均值、标准差、最大值，窗口截止 t。总计 91 列候选输入。14 天 LSTM 样本仅由历史序列组成；候选可使用最后 7 天或 14 天。

月份不是普通大小顺序：12 月与 1 月在季节上相邻，直接使用整数 1 至 12 会把两者放到数轴两端。因此月份用正弦和余弦表达周期，四季用独热编码表达离散类别。滞后 0 表示起报日当天已观测值，滞后 1 表示前一日；滚动窗口的右端固定在 t，绝不使用 t+1 及以后的真实量。特征名称和日期索引同时检查，避免仅凭数组形状正确就误把未来标签移入输入。

常见缩放包括 Min-Max、Z-score、鲁棒缩放；本次使用 Z-score。常见选择法包括过滤、包装、嵌入；本次以逐目标互信息的平均值排序，选择 16 或 24 列。全部拟合限于本折训练行；正式模型以全部训练期拟合后只 transform 测试输入。

Min-Max 把训练值映射到固定区间，便于比较量纲，却容易受训练期极值影响；Z-score 按训练均值和标准差中心化，在本实验中作为统一数值输入；鲁棒缩放用分位数降低极端值对参数估计的影响。三者都只应在训练折拟合参数，验证折和 2004 数据只应用已拟合参数。

互信息属于过滤式选择，先给候选输入与目标的依赖打分，再在训练折内按所需数量截取；本实验对七个输出分别评分并取平均排名，形成多输出共用特征，而不是在测试年重新选列。



训练特征 Z-score 处理前后分布

feature	MI
Discharge_lag0	1.9113
Discharge_roll3_mean	1.4693
Discharge_roll3_max	1.3474
Discharge_lag1	1.3104
Discharge_roll7_mean	1.1570
Discharge_lag2	1.0636
Discharge_roll7_max	1.0621
Discharge_roll14_mean	1.0247
Tmax_roll14_max	1.0043
Discharge_roll14_max	0.9546
Tmin_roll14_max	0.9390
Discharge_lag3	0.9141

网格搜索和目标变换

训练期先导搜索显示 h=1 验证 R^2 约 0.67—0.69，随后加入相对当天已知径流的残差候选。目标候选为原始值、平方根和 log1p；残差方案在相应目标尺度预测相对 Q(t)的变化，再逆变换恢复流量。最终模型均由冻结网格决定，测试结果不反向影响选择。

ANN 为单隐层 MLP；RF 使用 120 棵树并搜索叶节点最小样本数；LSTM 为单层循环网络、线性输出头和 Adam 优化器。七输出网络不是七个独立包装器。LSTM 以 purged CV 选择 30 或 70 轮训练，不采用随机验证集早停。

模型	CV R^2	目标变换	k	参数
直/RF/h1	0.6925	log	24	leaf=1, residual=True, trees=120
直/RF/h2	0.5023	log	24	leaf=1, residual=True, trees=120
直/RF/h3	0.3798	log	24	leaf=1, residual=True, trees=120
直/RF/h4	0.3275	log	24	leaf=1, residual=True, trees=120
直/RF/h5	0.2717	log	24	leaf=1, residual=True, trees=120
直/RF/h6	0.2550	log	24	leaf=1, residual=True, trees=120
直/RF/h7	0.2843	log	24	leaf=1, residual=True, trees=120
直/ANN/h1	0.7076	log	24	alpha=0.1, hidden=64, iterations=350, residual=True
直/ANN/h2	0.4665	sqrt	24	alpha=0.1, hidden=64, iterations=350
直/ANN/h3	0.3748	log	24	alpha=0.1, hidden=64, iterations=350, residual=True
直/ANN/h4	0.2903	sqrt	24	alpha=0.1, hidden=32, iterations=350
直/ANN/h5	0.2555	log	24	alpha=0.1, hidden=32, iterations=350
直/ANN/h6	0.1943	log	24	alpha=0.1, hidden=32, iterations=350
直/ANN/h7	0.2184	log	24	alpha=0.1, hidden=64, iterations=350
直/LSTM/h1	0.6747	sqrt	16	alpha=0.1, epochs=70, hidden=32, seq_len=14
直/LSTM/h2	0.2720	log	16	alpha=0.1, epochs=70, hidden=32, seq_len=14
直/LSTM/h3	0.1870	log	16	alpha=0.1, epochs=70, hidden=32, seq_len=14

模型	CV R^2	目标变换	k	参数
直/LSTM/h4	0.1006	log	16	alpha=0.1, epochs=70, hidden=32, seq_len=14
直/LSTM/h5	0.0051	log	16	alpha=0.1, epochs=70, hidden=32, seq_len=14
直/LSTM/h6	-0.0403	raw	16	alpha=0.1, epochs=30, hidden=32, seq_len=7
直/LSTM/h7	0.1168	raw	16	alpha=0.1, epochs=30, hidden=32, seq_len=7
多/RF/h7	0.4019	log	24	leaf=1, residual=True, trees=120
多/ANN/h7	0.3058	log	24	alpha=0.1, hidden=32, iterations=350
多/LSTM/h7	0.2298	log	16	alpha=0.1, epochs=70, hidden=32, seq_len=14

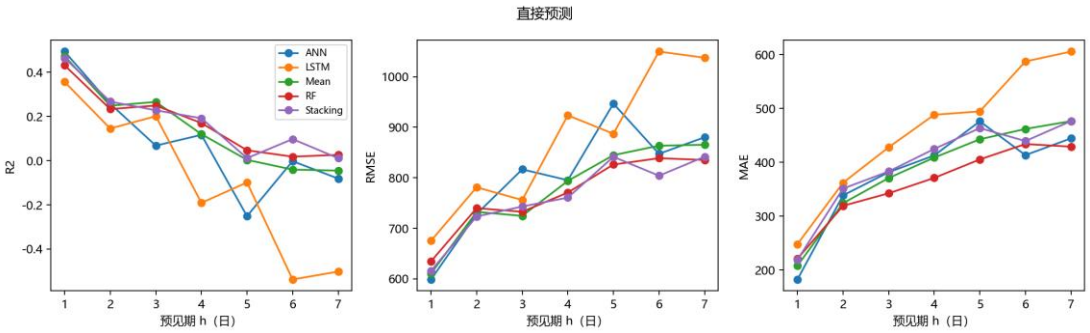
正式预测与集成结果

$R^2=1-\Sigma(y-\hat{y})^2/\Sigma(y-\bar{y})^2$；RMSE 为均方误差平方根，MAE 为绝对误差均值。R^2 允许为负数，不截断也不将其改为相关系数平方。所有预测通过相同非负约束处理，指标保持原始尺度。

R^2 的分母使用本次同一预见期 359 个真实值相对其均值的总平方差，因此不同预见期要分别计算，不能把七天预测先拼接后冒充逐日结果。水文领域常用的 Nash–Sutcliffe 效率与此形式一致[6]。RMSE 会更重地惩罚少数大误差，MAE 反映平均绝对偏差；当洪峰稀少且幅值高时，三个指标可能给出不同的模型排序。报告同时列出持续性基线，即用起报日实测流量预测未来各日，以确认复杂模型是否真正超过简单参照。

简单平均对三个基模型原尺度预测等权平均。Stacking 仅用训练期嵌套 OOF 预测拟合 Ridge；直接策略每 h 三列元特征，多输出为 21 列基预测到七个目标。两种集成均为实际生成结果，未退回单模型代替。

多步直接预测



direct 策略七个预见期的 R^2/RMSE/MAE

direct / ANN

h	R2	RMSE	MAE
1	0.4942	598.8176	182.3914
2	0.2577	728.2681	338.4987
3	0.0682	816.6148	381.3998
4	0.1171	795.2342	412.6272
5	-0.2511	946.7878	475.8820
6	-0.0021	847.4309	413.1931
7	-0.0810	880.2005	444.3475

direct / RF

h	R2	RMSE	MAE
1	0.4318	634.6771	220.8107
2	0.2337	739.9311	319.0979
3	0.2498	732.7452	342.3241
4	0.1704	770.8332	370.8884
5	0.0472	826.2252	405.2310
6	0.0183	838.7727	433.8017
7	0.0265	835.2885	428.9357

direct / LSTM

h	R2	RMSE	MAE
1	0.3566	675.3769	247.9225

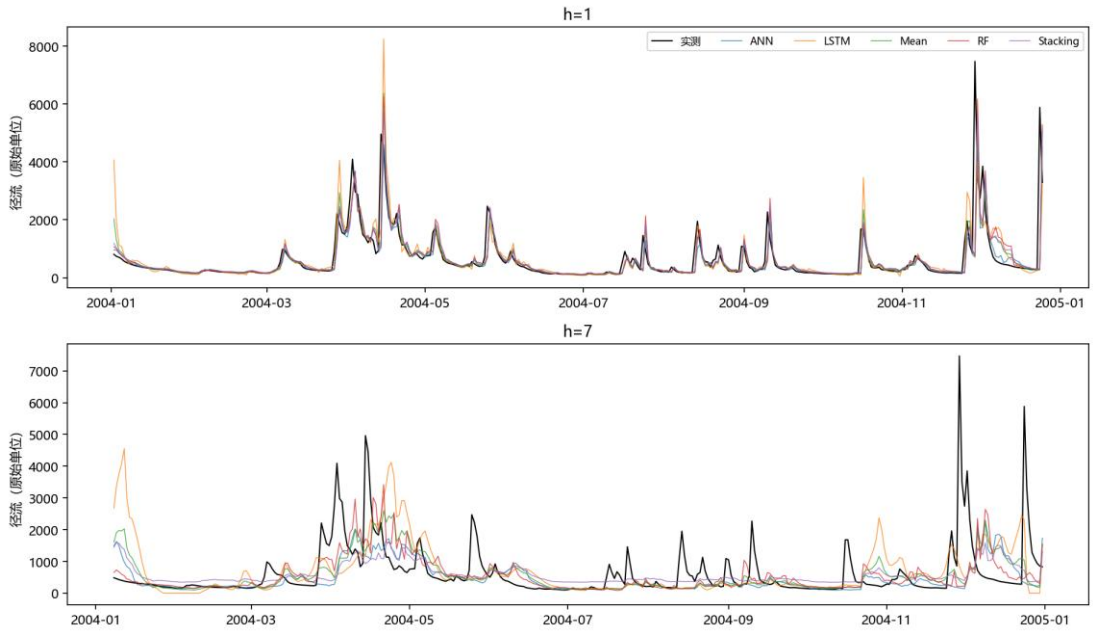
h	R2	RMSE	MAE
2	0.1458	781.2381	361.8354
3	0.2015	755.9611	427.7080
4	-0.1910	923.5933	488.1249
5	-0.0985	887.1650	494.3929
6	-0.5378	1049.7845	587.1023
7	-0.5021	1037.5586	605.4733

direct / Mean

h	R2	RMSE	MAE
1	0.4739	610.7352	207.8408
2	0.2489	732.5713	323.9302
3	0.2662	724.6497	370.6467
4	0.1201	793.8433	408.6075
5	0.0040	844.7856	442.6253
6	-0.0404	863.4848	461.8179
7	-0.0449	865.3837	476.3043

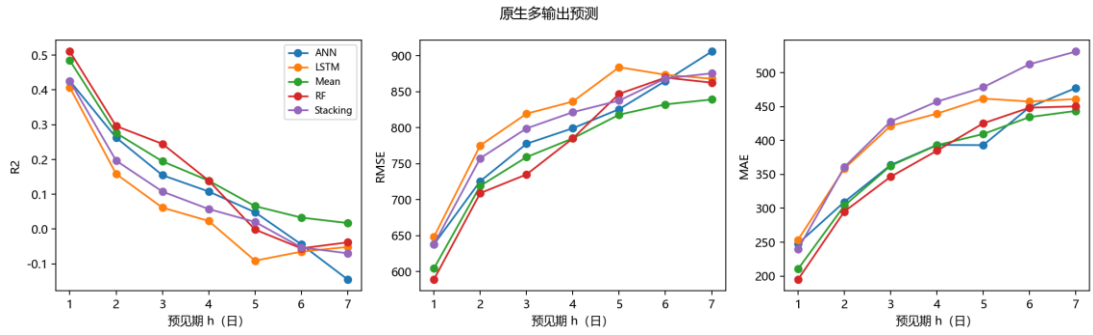
direct / Stacking

h	R2	RMSE	MAE
1	0.4650	615.8546	218.8492
2	0.2676	723.3911	351.1035
3	0.2283	743.1626	382.8248
4	0.1920	760.7123	424.6628
5	0.0116	841.5334	463.4503
6	0.0978	804.0869	439.3096
7	0.0113	841.7705	476.4405



direct 策略 h=1 及 h=7 实测与预测过程线

原生多输出预测



multi 策略七个预见期的 R^2/RMSE/MAE

multi / ANN

h	R2	RMSE	MAE
1	0.4259	637.9762	247.8826
2	0.2629	725.6978	309.3463
3	0.1549	777.6882	363.7698
4	0.1081	799.2502	393.4532
5	0.0484	825.7130	393.1923
6	-0.0439	864.9305	449.1616
7	-0.1447	905.7787	477.3537

multi / RF

h	R2	RMSE	MAE
1	0.5103	589.1977	194.9932
2	0.2962	709.1346	295.1697
3	0.2450	735.0453	346.5209
4	0.1393	785.1518	384.9404
5	-0.0013	847.0046	425.3475
6	-0.0553	869.6152	448.4284
7	-0.0382	862.5863	450.3142

multi / LSTM

h	R2	RMSE	MAE
1	0.4071	648.3166	253.5282
2	0.1585	775.3929	358.5284
3	0.0617	819.4395	421.5686
4	0.0234	836.3399	439.5946
5	-0.0908	884.0391	461.8183
6	-0.0649	873.5556	457.4915
7	-0.0513	868.0084	461.1568

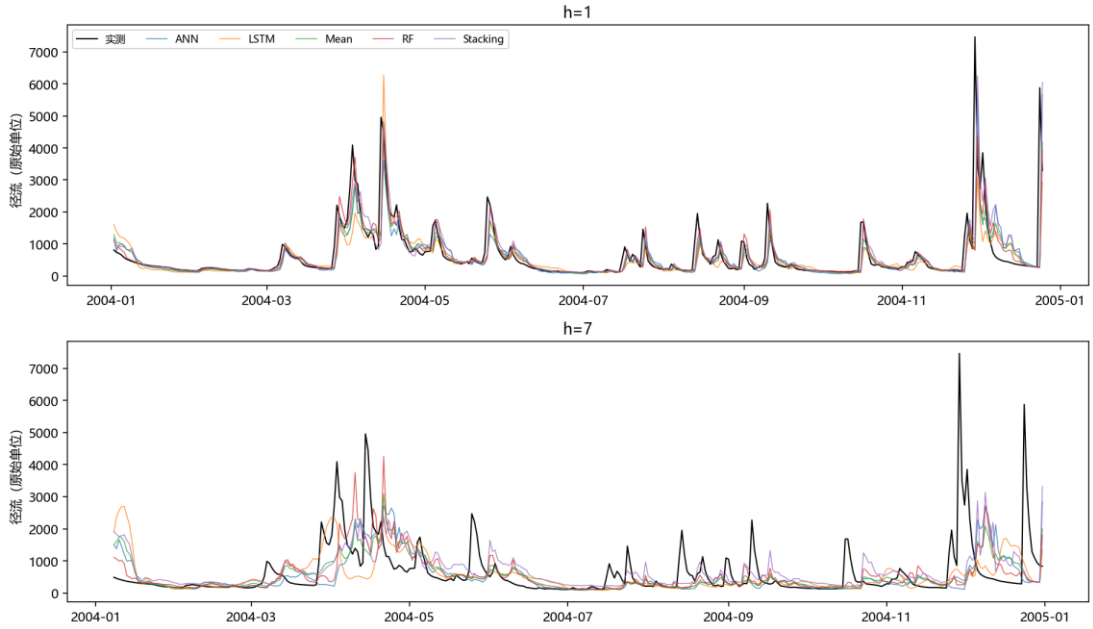
multi / Mean

h	R2	RMSE	MAE
1	0.4846	604.4994	210.3443
2	0.2761	719.1877	303.9155
3	0.1948	759.1292	362.7424
4	0.1391	785.2226	393.0208
5	0.0660	818.0692	409.5408
6	0.0331	832.4165	434.5707
7	0.0174	839.1684	443.5777

multi / Stacking

h	R2	RMSE	MAE
1	0.4259	637.9748	239.8919

h	R2	RMSE	MAE
2	0.1967	757.5899	360.7756
3	0.1079	799.0329	428.1060
4	0.0576	821.5540	457.2885
5	0.0207	837.6694	478.5355
6	-0.0526	868.5013	512.5432
7	-0.0695	875.5047	531.1983



multi 策略 h=1 及 h=7 实测与预测过程线

持续性基线与误差分析

h	R2	RMSE	MAE
1	0.3988	652.8319	214.4568
2	0.0603	819.4180	333.9638
3	-0.0533	868.2383	403.7827
4	-0.2447	944.1941	458.1811
5	-0.3992	1001.2553	494.0056
6	-0.4778	1029.0756	521.8830
7	-0.5815	1064.6259	538.0864

正式 h=1 最高 R^2 模型的 20 个最大误差日占其平方误差总和的 91.1%。该统计只用于冻结后的解释，未用来重选模型。极端值被保留；若模型对少数洪峰误差较大，R^2 与 RMSE 会明显

下降，MAE 则相对不敏感。

origin	target_date	truth	prediction
2004-11-28	2004-11-29	7470.0000	799.5539
2004-12-23	2004-12-24	5880.0000	277.6002
2004-04-13	2004-04-14	4960.0000	1224.3831
2004-12-01	2004-12-02	3850.0000	1932.6751
2004-05-24	2004-05-25	2470.0000	670.8723
2004-09-09	2004-09-10	2270.0000	567.9027
2004-10-15	2004-10-16	1680.0000	157.8545
2004-03-27	2004-03-28	2210.0000	997.3121

正式结果与后续研究的边界

正式冻结结果中，h=1 最高为原生七输出 RF：R^2=0.510331、RMSE=589.198、MAE=194.993；同日期持续性基线 R^2=0.398849。直接 ANN 的 h=1 R^2 为 0.494210，不能仅因其 MAE 更低就改称为 R^2 最优。正式结果包含三类个体模型、两种集成和两种策略的 70 行逐预见期指标。上述数值来自同一冻结运行，并非把不同实验中各自最好的预见期拼成一个模型。

正式运行之后，项目又进行第一天精度研究。一次固定单种子 ANN 回溯得到 R^2=0.506473；另一份加入当天降雨的固定三种子 ANN 回溯得到 R^2=0.503079，两者都在相同 359 个起报点上低于正式 RF 的 0.510331。其余训练期方案，包括目标一致互信息、单输出 RF 和梯度提升树，保留为开发期对照，没有新的 2004 成绩，也未替换教师要求的 40 个正式模型。开发期某一年或某个种子的高分不能写成正式测试精度；2004 此前已被查看，所有相关成绩均属于回溯评价而非独立盲测。

从图中的过程线可以看到，模型对平稳低流量区间的走势通常更容易跟随，而洪峰到来的时间和幅度更难同时命中。把大误差日单独列出，是为解释 R^2 和 RMSE 为何受少数日期显著影响；这些日期仍完整保留在 359 个测试起报日中，不以“异常样本”为由删去。持续性基线在 h=1 已有一定分数，说明当天实测流量本身包含短期记忆；模型超过基线的幅度才是额外信息的实际贡献。随着预见期拉长，未来降水尚未发生，固定参数且只使用历史气象的模型信息会减少。因此本报告展示 h=1 至 7 的全部结果，包括负 R^2，不把后六天隐藏在一个均值里，也不对结果曲线施加单调约束。

五、程序调试

日期与多步标签边界：起初的实现需求只写按年份切分，不足以证明七步标签未跨界。先写因果与日期失败测试，再实现训练标签截止日断言、gap=7 和 359 个共同测试原点，边界测试通过。

输入/输出一致性：为 ANN、RF、LSTM 分别编写原生七输出、单输出列形状、训练折缩放和序列化恢复测试，确认预测矩阵与实测日期对应。残差扩展先由失败测试暴露不支持参数，再验证在零变化目标下能重构当天流量。

ANN 收敛：快速单元测试故意只运行 10 轮，会出现 ConvergenceWarning；正式训练的警告数量记录在每个搜索 JSON 中，不隐藏为已完全收敛。网格预算固定，未在正式测试后追加轮次。

正式 96 组搜索累计记录 37 条收敛警告（含未胜出的候选和 OOF 内搜索），说明有限预算下部分 ANN 候选未充分收敛。它们是优化预算限制，不能据此把测试分数解释为理论上限。

文档转换：打包渲染器缺少 LibreOffice 可执行文件，已记录错误。改用 Microsoft Word 转换教师.doc 副本并导出 PDF，通过逐页图像检查报告版面；没有改变教师原文件。

六、总结

使用技术：pandas 日期索引、numpy 序列、matplotlib 可视化、Pearson 分析、月份正余弦/季节 one-hot、滞后/滚动、互信息、Z-score、MLP、随机森林、PyTorch LSTM、GridSearchCV、purged TimeSeriesSplit、嵌套 OOF、Ridge Stacking 和 Git 版本记录。

本次全部模型最高 h=1 R^2 为 0.5103。未实现约 0.8 的性能目标，应将这一点作为结果限制，而不是用训练分数替代测试分数。预见期越长，可用历史对未来的解释力可能下降，但不强迫指标单调。

当前限制包括四年训练数据较少、气象只截至 t、有限网格和单随机种子。后续如有新的合法独立数据，可预先设计验证期，再研究更多历史窗口、洪峰加权损失或多种子稳定性；本次不能用 2004 结果继续选参。由于 2004 已在旧实验查看，本次属于冻结配置后的回溯评价。

本实验说明，时间序列任务的日期可用性和评价协议与网络结构同样重要。应用于防洪等实际场景时，应同时检查平均误差、洪峰漏报和预报时效，不能仅依据一个 R^2 宣布可部署。个人心得及成员协作体会待三位成员按实际参与补充。

从失败研究中得到的具体认识是：更复杂的表示并不会自动带来更高的测试分数。训练期加入当天降雨在困难年份有小幅改善，但授权回溯后仍低于正式 RF；固定网格的平方根增量提升树在训练期三年都超过其原流量目标版本，困难年却仍低于既有 ANN 验证成绩。两项比较的因果范围不同，不能把训练期进步、回溯期进步和未来部署效果划等号。后续改进应先在新的合法独立年份预先锁定评价方案，再检验洪峰日和全年指标是否共同改善。

本项目还暴露出模型选择与性能表述之间的区别。开发期的交叉验证用于从有限候选中选配置，分数会受年份水文过程、搜索次数和随机种子影响；它不是对未见年份的承诺。2004 回溯只能回答固定模型在这一历史年份的表现，不能证明同样分数会在另一流域或未来洪水中重现。实际使用前还需要确认气象与流量观测能按预测时刻及时到达，检查缺测与设备故障时如何回退，并按防洪业务对漏报洪峰的代价建立单独评价。由于这些数据和场景没有在

本课程资料中提供，本报告不声称完成业务部署。真实小组分工和个人收获也应由三名成员按实际工作补写，避免把统一的技术记录误当成每个人相同的贡献。

参考文献

[1] Thornton M M, Shrestha R, Wei Y, et al. Daymet Daily Surface Weather Data on a 1 km Grid for North America Version 4. ORNL DAAC, 2020. DOI:10.3334/ORNLDAAC/1840.

[2] Breiman L. Random Forests. Machine Learning, 2001, 45:5–32. DOI:10.1023/A:1010933404324.

[3] Hochreiter S, Schmidhuber J. Long Short-Term Memory. Neural Computation, 1997, 9(8):1735–1780. DOI:10.1162/neco.1997.9.8.1735.

[4] Wolpert D H. Stacked Generalization. Neural Networks, 1992, 5(2):241–259. DOI:10.1016/S0893-6080(05)80023-1.

[5] Pedregosa F, Varoquaux G, Gramfort A, et al. Scikit-learn Machine Learning in Python. Journal of Machine Learning Research, 2011, 12:2825–2830.

[6] Nash J E, Sutcliffe J V. River Flow Forecasting Through Conceptual Models Part I A Discussion of Principles. Journal of Hydrology, 1970, 10(3):282–290. DOI:10.1016/0022-1694(70)90255-6.

[7] Rumelhart D E, Hinton G E, Williams R J. Learning Representations by Back-Propagating Errors. Nature, 1986, 323:533–536. DOI:10.1038/323533a0.

附录 代码提交说明

本报告不粘贴源码。工程代码应作为独立文件提交；项目运行入口为 python code/run_all.py，验证入口为 python -m pytest tests -q。

复现时需将教师原 CSV 置于 Teacher Resources & Requirements/01047000.csv。数据不随代码包重复分发，SHA-256：ab09410b23118510bb4e8787a62b97693336a1c46477a01329f587c64bc57151。

运行标识：formal_20261105_clean；训练源码提交：d7d5f34d821d746cc622fe0bcc9178c2106db86f。正式运行清单和冻结参数随阶段验收附件提供。整体提交压缩包需待真实组号、组长及两位组员姓名确认后按教师规则命名。